

# Comparación Arquitecturas CNN

ClasifEye

Mayo 2025

## Descripciones de Arquitecturas CNN Comunes

### GoogLeNet (Inception) (2014)

**Idea Clave:** Introdujo el “módulo Inception”, que realiza convoluciones con diferentes tamaños de filtro (1x1, 3x3, 5x5) y pooling en paralelo, y luego concatena sus salidas. Esto permite a la red capturar características a múltiples escalas. También se centró en la eficiencia computacional.

**Por qué Común/Importante:** Ganó el ILSVRC 2014. Demostró cómo un diseño de red bien pensado podía alcanzar alta precisión con menos parámetros que VGG. Versiones subsecuentes (Inception v2, v3, v4, Inception-ResNet) refinaron aún más esta idea.

### ResNet (Redes Residuales) (2015)

**Idea Clave:** Introdujo “conexiones de salto” (“skip connections”) o “bloques residuales” para abordar el problema del gradiente desvaneciente, permitiendo el entrenamiento de redes extremadamente profundas (ej. ResNet-50, ResNet-101, ResNet-152, e incluso más profundas). La conexión de salto permite a la red aprender una función identidad si una capa no es útil.

**Por qué Común/Importante:** Revolucionó cómo se construyen las redes profundas. Ganó el ILSVRC 2015. Podría decirse que las ResNets son el “backbone” más común para la gran mayoría de las tareas de visión por computadora hoy en día debido a su excelente rendimiento y capacidad para entrenar en profundidad.

### DenseNet (Redes Convolucionales Densamente Conectadas) (2017)

**Idea Clave:** Cada capa está conectada a todas las demás capas de manera “feed-forward”. Esto fomenta la reutilización de características, fortalece la propagación de características y puede llevar a una mejor eficiencia de parámetros.

**Por qué Común/Importante:** Una evolución interesante de la idea de conectividad de ResNet, que a menudo logra grandes resultados con menos parámetros.

### MobileNets (2017-2019)

**Idea Clave:** Diseñadas específicamente para aplicaciones de visión en móviles y sistemas embebidos. Utiliza “convoluciones separables en profundidad” (“depthwise separable convolutions”) para reducir significativamente el cómputo y el tamaño del modelo, manteniendo una precisión razonable.

**Por qué Común/Importante:** Cruciales para la IA en el dispositivo (“on-device AI”). Hicieron que las CNNs de alto rendimiento fueran prácticas para entornos con recursos limitados. Muchas variantes como ShuffleNet y SqueezeNet también se centran en la eficiencia.

### EfficientNet (2019)

**Idea Clave:** Escala sistemáticamente la profundidad, el ancho y la resolución de la red utilizando un método de “escalado compuesto”, a menudo encontrado mediante la búsqueda de arquitectura neural (NAS).

**Por qué Común/Importante:** Logró resultados de vanguardia en ImageNet con significativamente menos parámetros y FLOPs que los modelos anteriores, demostrando una forma más fundamentada de escalar las CNNs.

Cuadro 1: Comparación de Arquitecturas CNN Comunes (Últimas 5 Bases)

| Característica                   | GoogLeNet                                                                                              | ResNet                                                                                             | DenseNet                                                                                          | MobileNets                                                                                | EfficientNet                                                                                  |
|----------------------------------|--------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|
| Año                              | 2014                                                                                                   | 2015                                                                                               | 2017                                                                                              | 2017-2019                                                                                 | 2019                                                                                          |
| Innovación Clave                 | Módulo "Inception" (procesamiento multiescala con convoluciones 1x1 para reducción de dimensionalidad) | Bloques Residuales (conexiones de salto o "skip connections")                                      | Conectividad Densa (cada capa conectada a todas las capas subsecuentes)                           | Convoluciones Separables en Profundidad (v2 añade residuales invertidos, v3 añade NAS/SE) | Escalado Compuesto (profundidad, ancho, resolución), Búsqueda de Arquitectura Neural (NAS)    |
| Objetivo Principal               | Alta precisión con eficiencia computacional (menos parámetros que VGG)                                 | Permitir el entrenamiento de redes muy profundas, resolver el problema del gradiente desvaneciente | Reutilización de características, eficiencia de parámetros, mejora del flujo de gradientes        | Eficiencia extrema para dispositivos móviles/embebidos (baja latencia, tamaño pequeño)    | Precisión de vanguardia con eficiencia superior en parámetros y FLOPs                         |
| Fortaleza                        | Captura de características a múltiples escalas de forma eficiente                                      | Entrenamiento de redes extremadamente profundas, excelente generalización                          | Alta eficiencia de parámetros, fuerte propagación de características                              | Ligeras, inferencia rápida en dispositivos con recursos limitados                         | Mejor equilibrio entre precisión y coste computacional (en su momento)                        |
| Casos de Uso Típicos             | Clasificación de imágenes, extracción de características (como "backbone")                             | "Backbone" para la mayoría de tareas modernas de CV (clasificación, detección, segmentación)       | Clasificación de imágenes, tareas que requieren alta eficiencia de parámetros (ej. imagen médica) | Visión en dispositivo (apps móviles, sistemas embebidos)                                  | Clasificación de alto rendimiento, aprendizaje por transferencia donde la eficiencia importa  |
| Coste Computacional / Parámetros | Moderado (menor que VGG para un rendimiento similar)                                                   | Varía (ej. ResNet-18 es más ligera, ResNet-152 es más pesada). Generalmente moderado a alto.       | Generalmente menor que ResNets para una precisión similar                                         | Muy Bajo                                                                                  | Varía (B0 muy pequeña, B7 grande), pero altamente eficiente <i>para su nivel de precisión</i> |

## Boceto Inicial de Arquitectura

En esta sección, se presenta un diseño preliminar de la arquitectura propuesta para nuestro sistema de clasificación de rostros humanos, que debe predecir simultáneamente edad, sexo y raza. El objetivo es establecer un flujo de procesamiento claro y discutir la viabilidad de utilizar un modelo multi-tarea frente a modelos separados para cada tarea. A continuación, se muestra un diagrama de flujo de alto nivel que ilustra las etapas principales del sistema, seguido de una discusión sobre la estrategia de modelado.

### Diagrama de Flujo

El siguiente diagrama representa el flujo de procesamiento desde la entrada de la imagen hasta la obtención de los resultados:




Figura 1: Diagrama de flujo de alto nivel para el sistema de clasificación de rostros.

### Aspectos a considerar de nuestro proyecto

- **Aprendizaje Multi-Tarea:** El modelo necesitará una estructura que pueda predecir las tres salidas simultáneamente. Esto usualmente implica un “tronco” (*backbone*) compartido y luego “cabezas” (*heads*) de clasificación separadas para cada tarea (edad, sexo, raza).
- **Uso de recursos:** En esta etapa, nuestro proyecto prioriza la precisión y la capacidad de capturar características complejas sobre la eficiencia computacional. Dado que estamos enfocados en lograr un alto rendimiento en la clasificación de rostros humanos, la optimización de recursos no es una prioridad inmediata. Sin embargo, reconocemos que la eficiencia podría ser relevante en el futuro, especialmente si consideramos implementar el modelo en entornos con recursos limitados, como dispositivos móviles. Arquitecturas más ligeras, como MobileNets, podrían ser evaluadas en ese caso, ya que ofrecen un buen balance entre precisión y bajo consumo de recursos.
- **Complejidad:** Al trabajar con caras humanas, que pueden ser tan distintas y complejas, tenemos que buscar una arquitectura lo suficientemente profunda para poder detectar esos rasgos que nos permitirán hacer predicciones.

## Conclusión

Los modelos que tienen más potencial para nuestro proyecto son ResNet y DenseNet, ya que ofrecen la mayor profundidad y, además, son los más populares para este tipo de proyectos.